

PROYECTO CREAN

Resumen técnico de la solución analítica

Integración de datos, ingeniería de variables, clasificación, perfilamiento, regresión y preparación de resultados para Power BI.

Objetivo técnico: construir una solución reproducible que integre las fuentes financieras a nivel cliente, identifique afinidad hacia productos de inversión y estime el monto potencial, manteniendo trazabilidad y evitando fuga de información.

1. Arquitectura general de la solución

La solución se estructuró como un flujo analítico secuencial: **fuentes SQLite** → **integración** → **calidad y transformación** → **variables analíticas** → **clasificación** → **perfilamiento** → **regresión** → **exportación de resultados** → **Power BI**. La variable **es_inversionista** se utilizó como proxy de afinidad histórica basado en la tenencia actual de productos de inversión; por tanto, no representa una adopción futura observada de la App.

Componentes principales

- **Clasificación:** estimar la probabilidad de que un cliente presente perfil inversionista.
- **Perfilamiento:** separar inversionistas en perfiles de inversión menor y mayor para caracterizar comportamientos heterogéneos.
- **Regresión:** estimar el monto potencial de inversión y analizar el error por nivel de inversión.
- **Arquitectura jerárquica:** experimento de clasificación del nivel de inversión y regresores especializados por segmento.

2. Integración y construcción de la tabla analítica

Las fuentes fueron entregadas en bases SQLite independientes. Se conectaron con Python mediante **sqlite3** y se consolidaron a nivel de **numero_id**. Se realizaron agregaciones por producto antes de los LEFT JOIN para conservar una granularidad de una fila por cliente y evitar duplicaciones.

Bloque de información	Ejemplos de variables
Clientes	grupo_edad, desc_genero, desc_segmento, tipo de vivienda, ingresos, egresos, activos, pasivos, patrimonio
Productos	Bolsillos, ahorro, corriente, Fiducuenta, inversión virtual, CDT e Investbot
Agregaciones	saldo actual, promedio, máximo, mínimo, meses activos e indicador de tenencia por producto
Variables derivadas	estimador_ingreso, total_inversiones, liquidez, total_ahorro, capacidad_ahorro, ratio_endeudamiento, conteos de productos

La tabla analítica llegó a manejar cientos de miles de clientes y decenas de variables. Antes del modelado se revisaron duplicados, tipos de datos, faltantes, infinitos, valores extremos y consistencia de identificadores.

3. Preparación para modelado

- Las variables categóricas se procesaron mediante imputación y **OneHotEncoder**.
- Las variables numéricas utilizaron imputación; para modelos lineales se incorporó escalado estándar.
- Se aplicaron transformaciones logarítmicas en variables monetarias altamente asimétricas para reducir el efecto de colas largas.
- Los objetos de preprocesamiento se encapsularon en **Pipeline** y **ColumnTransformer** de scikit-learn.
- La selección, imputación, escalado, codificación y definición de puntos de corte se ajustaron usando Train/Validation; Test se reservó para evaluación final.

Control de fuga de información: variables que definen directa o indirectamente el objetivo, como total_inversiones o conteos directamente asociados a productos de inversión, no deben utilizarse como predictores del clasificador cuando revelan el target.

4. Modelo de clasificación - propensión / afinidad

Se compararon modelos de clasificación y se evaluaron métricas complementarias: Accuracy, Balanced Accuracy, Precision, Recall, F1, ROC-AUC y PR-AUC. También se revisó el umbral de decisión en Validation para equilibrar identificación de oportunidades y errores de clasificación.

Métrica final	Resultado
Accuracy	87,10 %
Balanced Accuracy	83,60 %
Precision	74,28 %
Recall	76,39 %
F1	75,32 %
ROC-AUC	91,51 %
PR-AUC	81,82 %

En el conjunto exportado para Power BI se evaluaron **171.074 clientes** y aproximadamente **26,5 %** fueron predichos como inversionistas. La matriz de resultados permitió distinguir verdaderos positivos, verdaderos negativos, falsos positivos y falsos negativos.

La importancia del clasificador mostró un peso dominante de variables relacionadas con **Bolsillos**, especialmente la tenencia y el comportamiento de saldos, seguidas por liquidez, ahorro, edad, activos y segmento.

5. Perfilamiento de inversionistas

Los clientes identificados históricamente como inversionistas se caracterizaron en dos perfiles: **Inversión mayor** e **Inversión menor**. La población observada fue de 220.452 inversionistas: 138.293 (62,73 %) en inversión mayor y 82.159 (37,27 %) en inversión menor.

- Se compararon perfiles por grupo de edad, segmento comercial, distribución de montos y tenencia de productos.
- Para variables monetarias se priorizó la mediana cuando los outliers podían distorsionar el promedio.
- Se usaron escalas logarítmicas para visualizar distribuciones de inversión con alta dispersión.

6. Modelo de regresión - estimación del monto

Se compararon **Ridge**, **Árbol de decisión**, **Random Forest** y **XGBoost Regressor**. Las métricas se calcularon tanto en escala logarítmica como en pesos: MAE, MedAE, RMSE y R^2 . XGBoost presentó el menor MAE_log entre los modelos comparados y se utilizó como modelo de referencia.

Modelo	MAE_log	RMSE_log	R^2 _log
XGBoost	2,928	3,541	0,216
Random Forest	2,954	3,550	0,212
Árbol	2,970	3,606	0,187
Ridge	3,072	3,646	0,169

KPI XGBoost en pesos	Resultado
MAE	\$20,67 millones
MedAE	\$2,65 millones
RMSE	\$67,82 millones
R^2	2,26 %

La diferencia entre MedAE, MAE y RMSE evidencia una distribución de errores con casos extremos. El R^2 en pesos es bajo, por lo que la estimación debe interpretarse como apoyo a segmentación/priorización y no como una predicción exacta del monto individual.

7. Interpretabilidad y variables relevantes

La importancia del modelo de regresión mostró como principal variable **tiene_bolsillos (38,95 %)**. También destacaron los grupos de edad 50-65 (11,26 %) y 65+ (10,44 %), el grupo 26-35 (6,63 %), el segmento Preferencial (6,33 %), el saldo promedio de ahorro transformado y la actividad de Bolsillos.

Variable	Importancia aprox.
tiene_bolsillos	38,95 %
grupo_edad_50-65	11,26 %
grupo_edad_65+	10,44 %
grupo_edad_26-35	6,63 %
desc_segmento_PREFERENCIAL	6,33 %
log_saldo_promedio_ahorro	4,17 %
actividad_bolsillo	3,37 %

8. Exportación y consumo en Power BI

Se generaron tablas finales específicas para visualización: cliente 360, resultados del clasificador, métricas, perfiles de inversión, resultados de regresión, error por nivel, comparación de modelos e importancias. En Power BI se corrigieron tipos y configuraciones regionales para decimales, se construyeron medidas DAX, rangos de probabilidad, porcentajes de propensión y visualizaciones en escala logarítmica.

El tablero quedó organizado en cuatro páginas: **Caracterización general** → **Potencial de adopción** → **Perfil del inversionista** → **Estimación del monto**.

9. Buenas prácticas y mantenimiento

- Mantener numero_id únicamente como identificador y no como predictor.
- No usar Test para seleccionar modelos, variables, hiperparámetros o umbrales.
- Versionar reglas de perfilamiento y puntos de corte.
- Monitorear deriva de datos, desempeño por segmento, estabilidad de probabilidades y errores de regresión.
- Reentrenar cuando cambien las fuentes, la definición del target o el comportamiento de los clientes.

Conclusión técnica: la solución tiene mayor fortaleza para clasificar y priorizar clientes con afinidad hacia inversión que para estimar con precisión el monto exacto. La regresión aporta una señal complementaria, especialmente útil cuando se interpreta junto con perfiles y variables financieras.

Nota metodológica

Los resultados descritos corresponden al desarrollo analítico realizado para la prueba CREAN y a las tablas exportadas al tablero. La afinidad histórica se usa como aproximación al potencial de adopción; una adopción futura real requeriría observar comportamiento posterior al lanzamiento y recalibrar el modelo.